

Untersuchung der Stärken und Schwächen des RT-1-X Modells bei der Robotermanipulation

Björn-Felix Dettmar
Wirtschaftsingenieurwesen KIT
Praktikum Kognitive
Automobile und Roboter

Jan Frieling
Wirtschaftsinformatik KIT
Praktikum Kognitive
Automobile und Roboter

Tom Olesch
Wirtschaftsinformatik KIT
Praktikum Kognitive
Automobile und Roboter

Abstract—Die Ausarbeitung "Untersuchung der Stärken und Schwächen des RT-1-X Modells bei der Robotermanipulation" untersucht das RT-1-X Modell im Kontext der Robotermanipulation. Das Foundation-Modell wurde auf dem Open X-Embodiment Datensatz trainiert. Die Autoren evaluieren das Modell sowohl in simulierten und realen Umgebungen, mit einem Franka Panda Roboterarm, um dessen Fähigkeiten und Einschränkungen zu ergründen. Das RT-1-X Modell zeigt eine solide Leistung in In-Distribution-Settings, wurde jedoch aufgrund von Distribution Shifts nicht erfolgreich auf neue, unbekannte Aufgaben und Umgebungen ohne vorheriges Finetuning getestet. Die Ausarbeitung betont die Bedeutung von Distribution Shift, bzw. der Berücksichtigung von visuellen Unterschieden zwischen Trainings- und Anwendungsumgebungen. Trotz der vielversprechenden Fähigkeiten des Modells in bekannten Szenarien, unterstreicht die Untersuchung die Notwendigkeit weiterer Forschung und Entwicklung, um die Generalisierungsfähigkeit von Roboterlernmodellen in vielfältigen realweltlichen Anwendungen zu verbessern.

I. EINLEITUNG

Große, leistungsstarke Modelle, die auf vielfältigen Datensätzen trainiert wurden, haben beeindruckende Erfolge bei der effizienten Bewältigung von Anwendungen in verschiedenen Bereichen gezeigt. Diese Foundation Models haben sich insbesondere in Bereichen wie Sprachverarbeitung und Computervision [1], [2], [3], [4] als Ausgangspunkt für viele verschiedene Aufgaben etabliert. Auch in anderen Bereichen sind Foundation Models von Interesse.

Im Bereich der Robotik werden üblicherweise Modelle für einen bestimmten Roboter in einer Umgebung trainiert. Sobald die Sensoren abgenutzt sind, der Roboter ersetzt wird oder eine neue Umgebung oder Aufgabe hinzukommt, muss das Modell erneut trainiert werden. Foundation Models haben das Potenzial, den Bereich der Skalierbarkeit zu erweitern, sodass ein Modell beliebig viele Roboter, Umgebungen und Aufgaben verarbeiten kann, während gleichzeitig die Robustheit und die Dateneffizienz verbessert werden [5]. Ein Hauptproblem bei der Implementierung von Foundation Models im Robotikbereich stellt die Verfügbarkeit von qualitativ hochwertigen, diversifizierten Robotikdatensätzen dar [6]. Der Open X-Embodiment Datensatz kann als Lösungsansatz für diese Problematik angesehen werden und zum Training von Foundation Models verwendet werden [7].

Um zu zeigen, dass Modelle die auf großen aufgabenunspezifischen Datensätzen trainiert wurden, bessere Ergebnisse

erzielen können, wurden drei Modelle auf den Daten des Open X-Embodiment-Datensatzes trainiert: das RT-1-X [8] und das RT-2-X [9] Modell wurden zunächst auf neun verschiedenen Datensätze trainiert. Ende 2023 wurde das auf 25 verschiedene Datensätze der Open X-Embodiment Sammlung trainierte Octo Modell [10] veröffentlicht.

Diese Ausarbeitung konzentriert sich hauptsächlich auf die Implementierung und Analyse des RT-1-X Modells. Insbesondere werden die Herausforderungen und Probleme bei der Implementierung des Modells in einer virtuellen Umgebung sowie auf einem Franka Panda Roboterarm untersucht. Anschließend wird die Leistungsfähigkeit des Modells ohne Anpassungen und Finetuning untersucht.

In Kapitel II werden dazu zunächst die notwendigen Grundlagen, insbesondere des Reinforcement Learnings vermittelt. In Kapitel III wird der Fokus auf die Foundation Models gelegt, die den aktuellen Stand der Technik abbilden und auch in dieser Arbeit in Form des RT-1-X Modells untersucht werden. Anschließend wird in Kapitel IV das Vorgehen bei der Evaluation des RT-1-X Modells und das Modell selbst dargestellt. Danach wird in Kapitel V und VI die Evaluation des Modells, zunächst in einer Simulationsumgebung und anschließend auf einem echten Franka Panda Roboterarm durchgeführt. Kapitel VII schließt mit der Zusammenfassung der Ergebnisse und einem kurzen Ausblick auf zukünftige Entwicklungen.

II. GRUNDLAGEN

Im Reinforcement Learning (RL) durchläuft ein Agent einen sequentiellen Entscheidungsprozess innerhalb einer Umgebung. Dieser Prozess ist durch Zustände, Aktionen, Policies, Rewardfunktionen und die Dynamik der Umgebung gekennzeichnet.

Formal wird eine Umgebung durch eine Menge von Zuständen S definiert, wobei jeder Zustand $s \in S$ einen möglichen Zustand der Umgebung darstellt. Ein Agent interagiert sequentiell mit der Umwelt auf der Basis eines Beobachtungsraums O , wobei jede Beobachtung $o \in O$ eine Funktion des Zustands darstellt.

Sequentiell, für jeden Zeitschritt t , wählt der Agent eine Aktion a_t aus einem Aktionsraum A . Jede Aktion $a_t \in A$ aktualisiert den Zustand der Umgebung gemäß einer Policy π . Eine Richtlinie $\pi : S \rightarrow A$ ist definiert als eine Abbildung

von Zuständen auf Aktionen mit dem Ziel, den erwarteten kumulativen Reward zu maximieren. Nach der Aktualisierung der Umgebung erhält der Agent die Beobachtung $O_t + 1$ und den Reward $R_t + 1$.

Die Rewardfunktion $R_t : S \times A \rightarrow \mathbb{R}$ ordnet jedem Zustands-Aktions-Paar einen skalaren Wert zu, der den unmittelbaren Nutzen der Ausführung der Aktion a im Zustand s angibt. Das Ziel des Agenten ist die Maximierung der erwarteten Summe der diskontierten Rewards über die Zeit, formalisiert als $\mathbb{E}[\sum_{t=0}^{\infty} \gamma^t R(s_t, a_t)]$, wobei $\gamma \in [0, 1]$ ein Diskontierungsfaktor ist, der unmittelbare und zukünftige Rewards ausgleicht.

Allerdings können durch Veränderungen in der Umgebung Probleme auftreten, da der Agent in der Lage sein muss, neue Beobachtungen zu verarbeiten. Deshalb, wie in Abbildung 1 zu sehen ist, ist es bei herkömmlichen RL-Agenten notwendig, den Agenten regelmäßig neu zu trainieren, da sich die Umgebung und Aufgaben in der Realität kontinuierlich verändern.

III. STAND DER TECHNIK

Um die Probleme herkömmlicher RL-Agenten zu lösen, bedarf es einer neuen Policy-Lernmethode, die sogenannten Foundation Models. Foundation Models können ohne zusätzliches Training über verschiedene Aufgaben, Embodiments und Umgebungen generalisieren, wodurch sie robuster gegenüber Veränderungen in der Realität sind. Um erfolgreich zu generalisieren, müssen Modelle in der Lage sein, eine Vielzahl von Beobachtungen zu verarbeiten und auf dieser Grundlage unterschiedliche Aktionen auf verschiedenen Embodiments zu generieren. Sie müssen auch in der Lage sein, in unvorhergesehenen Kontexten zu agieren [6]. Es gibt bereits verschiedene Ansätze zur Entwicklung von Foundation Models in dieser Domäne. Ein Ansatz ist die Normalisierung des Aktionsraums durch eine High-Level-Repräsentation [5]. Dabei wird der Beobachtungsraum standardisiert, sodass der Agent verschiedene Embodiments durch einen normalisierten Aktionsraum steuern kann. Dieser Ansatz ermöglicht die Steuerung einer Vielzahl von Embodiments. Allerdings birgt das Training von Foundation Models dieser Art mehrere Probleme. Eines davon ist der Bedarf an vielen Trainingsdatensätzen. Um eine umfassende Abdeckung von Embodiments, Environments und Tasks zu gewährleisten, ist es notwendig, die Trainingsdatensätze zu diversifizieren. Eine ausgewogene Balance der Trainingsdaten ist erforderlich, um Overfitting auf bestimmte Tasks, Environments oder Embodiments zu vermeiden. Darüber hinaus gibt es einen Mangel an Trainingsdatensätzen, die den zuvor genannten Anforderungen entsprechen.

IV. METHODIK

Zur Evaluation des *RT-1-X* Modells musste zunächst das Modell lokal implementiert werden. Anschließend musste überprüft werden, ob das Modell korrekt implementiert wurde. Dazu wurden Vergleiche der prädizierten Aktionen zu Expertentrajektorien durchgeführt. Bei der Implementierung des Modells auf einem realen Roboter musste außerdem eine Faktorenanalyse durchgeführt werden, um die Umgebung möglichst

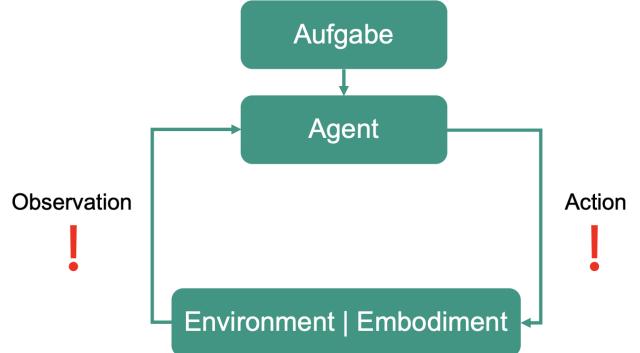


Fig. 1. Reinforcement Learning Kreislauf

genau nachzustellen. Zusätzlich wurde erneut eine Fehleranalyse durchgeführt um sicherzustellen, dass das Modell möglichst fehlerfrei implementiert wurde. Abschließend konnte eine Evaluation des Modells durchgeführt werden. Im Folgenden werden die Grundlagen des Open X-Embodiment Datensatzes und des verwendeten Modells dargestellt.

A. Open X-Embodiment Datensatz

Open X-Embodiment [7] verfolgt zwei Hauptziele, wobei das erste ist zu beweisen, dass Transfer Learning von Agenten auf unterschiedliche Aufgaben, Umgebungen und Roboter die Performance eines Agenten positiv beeinflusst. Das zweite Hauptziel ist es, eine Sammlung an Robotik-Datensätzen zu veröffentlichen, welche für die weitere Forschung verwendet werden können. Die Veröffentlichung adressiert die Probleme des High-Level-Repräsentation Ansatzes, indem es eine standardisierte Sammlung von Datensätzen mit über einer Million verschiedener Trajektorien auf 22 verschiedenen Embodiments für das Training von Robotik-Agenten veröffentlicht. Die Sammlung ist das Ergebnis der Zusammenarbeit von 25 verschiedenen Organisationen mit insgesamt 60 verschiedenen Datensätzen. Die Abbildung 2 gibt einen Überblick über die Verteilung der verschiedenen Embodiments, Aufgaben und verwendeten Objekte im Datensatz. Zur Demonstration der Relevanz des Datensatzes wurden mit der Veröffentlichung der Datensammlung auch zwei Modelle veröffentlicht: Das *RT-1-X* basiert auf dem *RT-1* [8] und das *RT-2-X* auf dem *RT-2* [9]. Beide Modelle haben die gleiche Architektur und wurden auf neun der 60 verschiedenen Datensätze trainiert. Das Modell *RT-1-X* verfügt über 35 Millionen Parameter, während das Modell *RT-2-X* über 55 Milliarden Parameter verfügt [7]. Das *RT-2-X* Modell ist ausschließlich über die API zugänglich, während das *RT-1-X* Modell mit dem aktuellen Checkpoint frei verfügbar ist.

B. RT-1-X Transformer

Das *RT-1-X* [7] basiert auf dem vorangegangenen *RT-1* Modell [8]. Die Architektur der Modelle ist identisch, lediglich die Auswahl der Trainingsdatensätze unterscheidet sich. Wie der Abbildung 3 zu entnehmen ist verwendet *RT-1-X* einen Transformer, der als Eingabe eine Bildserie von

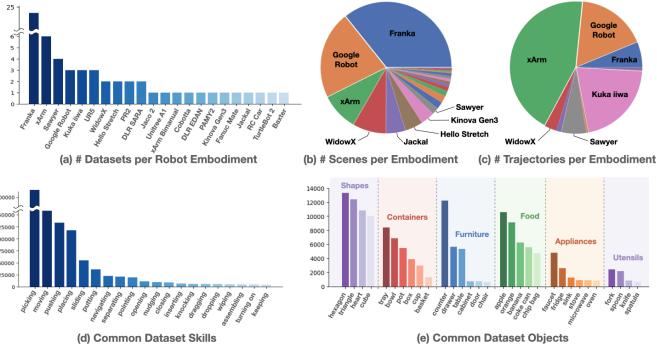


Fig. 2. Überblick Open X-Embodiment Datensatz. Open X-Embodiment [7]

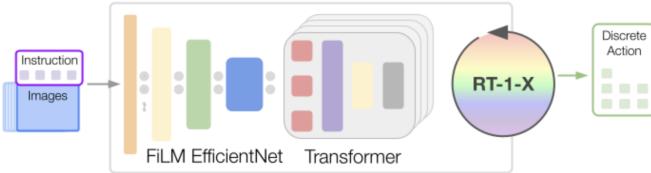


Fig. 3. RT-1-X Architektur. Angepasst von Open X-Embodiment [7]

RGB-Bildern erhält, die von einem FiLM [11] konditionierten EfficientNet Encoder [12] tokenisiert werden, sowie ein Text-Embedding. Zur Erstellung des Text-Embeddings wird der Universal Sentence Encoder 5 [13] verwendet. Das *RT-1-X* gibt als Aktion einen sieben-dimensionalen Vektor aus, der die Endeffektorposition steuert (x, y, z, Rollen, Gieren, Neigen und Gripper). Die Aktionen werden dabei nicht absolut vorgegeben, sondern in Form von Deltas.

Die Abbildung 4 zeigt für sechs verschiedene kleine Datensätze die Performance des Modells *RT-1-X* im Vergleich zum Modell *RT-1* und zu weiteren gewählten Baselines. *RT-1-X* übertrifft in allen sechs Aufgaben das *RT-1*, und in fünf von sechs Fällen auch die Baselines. Im Median erfüllt das *RT-1-X* Modell 63% der Aufgaben, während das *RT-1* Modell nur 44% und die Baselines 41% erfüllen. Allerdings sinkt die Performance des *RT-1-X* auf großen Datensätzen deutlich, wie aus Abbildung 5 hervorgeht. Es ist zu erkennen, dass das *RT-1-X* vom *RT-1* übertroffen wird. In der *Open X-Embodiment* Veröffentlichung wurden keine weiteren Bewertungen für das *RT-1-X* durchgeführt.

V. SIMULATIONSEVALUATION

Bei der Evaluation des *RT-1-X* Modells wurde zweistufig vorgegangen. Zunächst wurde das Modell in einer Simulationsumgebung implementiert, um schnell verschiedene Tests

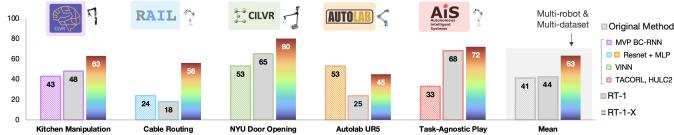


Fig. 4. RT-1-X Performance auf kleinen Datensätzen. Open X-Embodiment [7]

Evaluation Setting	Bridge	Bridge	RT-1 paper 6 skills
Evaluation Location	IRIS (Stanford)	RAIL Lab (UCB)	Google Robotic Lab
Robot Embodiment	WidowX	WidowX	Google Robot
Original Method	LCBC [95]	LCBC [95]	-
Original Method	13%	13%	-
RT-1	40%	30%	92%
RT-1-X	27%	27%	73%
RT-2-X (55B)	50%	30%	91%

Fig. 5. *RT-1-X* Performance auf großen Datensätzen. Angepasst von Open X-Embodiment [7]

durchführen zu können, und zu überprüfen, wie gut das Modell auf In-Distribution-Settings (Trainingsdatensätze) und auf Datensätzen funktioniert, auf denen es nicht trainiert wurde. Es wurden zwei Tests durchgeführt: Zunächst eine Offline-Evaluation mit vorgegebenen Bildinputs ohne Ausführung der Aktionen und anschließend eine Online-Evaluation in einer Simulation mit simulierter Bildeingabe. Im Folgenden werden das Vorgehen und die Ergebnisse der Simulationsevaluation erläutert.

TABLE I
OFFLINE-VALIDIERUNGS-DATENSÄTZE

Datensatz	Trainiert? ¹	Roboter	Umgebung
Freiburg Franka Play	ja	Franka	Real
TOTO Benchmark	ja	Franka	Real
Austin Buds	nein	Franka	Real
CMU Franka Exploration	nein	Franka	Real
Stanford Hydra	nein	Franka	Real
Maniskill v2	nein	Franka	Virtuell

¹ Wurde *RT-1-X* auf den Datensatz trainiert?

A. Offline-Evaluierung verschiedener Datensätze

Offline-Evaluierung bedeutet, dass ein Machine Learning Modell unabhängig von der realen Welt evaluiert wird. Dazu werden vorgegebene Inputs, wie zum Beispiel Bilder einer Expertentrajektorie, verwendet und die Aktionen, die das Modell vorhersagt, werden nicht tatsächlich ausgeführt [14]. In Tabelle I sind die Datensätze aufgeführt, für die eine Offline-Evaluierung durchgeführt wurde. Die Datensätze unterscheiden sich in erster Linie dadurch, dass einige für das Training des *RT-1-X* verwendet wurden und andere nicht. Außerdem basieren alle Datensätze auf realen Daten, ausgenommen *Maniskill v2*, dieser Datensatz wurde in einer Simulationsumgebung erzeugt. Für jeden Datensatz wurden iterativ Bilder einer ausgewählten Episode zusammen mit einer NLP-Anweisung dem *RT-1-X* Modell als Input vorgegeben. Das Modell prädizierte schrittweise Aktionen, welche anschließend mit den Aktionen der Datensatzepisode verglichen wurden. Es ist wichtig zu beachten, dass ein Abweichen von der Datensatz-Trajektorie nicht zwangsläufig bedeutet, dass die Aufgabe nicht erfüllt wurde. Eine Aufgabe kann grundsätzlich auf vielen verschiedenen Wegen ausgeführt werden.

1) *Ergebnisse der Offline-Evaluation:* Die Offline-Evaluierung ergab, dass das Modell für In-Distribution-Settings Trajektorien prädizierte, die eine hohe Ähnlichkeit

zu den Expertentrajektorien aufwiesen. Für Episoden aus Datensätzen, die nicht für das Training des *RT-I-X* Modells verwendet wurden, kam es hingegen zu signifikanten Abweichungen. In Abbildung 6 sind diese Abweichungen beispielhaft für den Datensatz *Maniskill v2* dargestellt, der in einer Simulationsumgebung erstellt wurde. In orange ist die Ground Truth, also die Expertentrajektorie dargestellt, in blau die Prädiktion des *RT-I-X*. Um zu überprüfen ob trotz der Abweichungen von der Expertentrajektorie die gestellte Aufgabe erfüllt wurde, wurden die Aktionen in den Simulationsumgebungen *RLBench* und *Maniskill2* ausgeführt. Die Simulationsumgebung verarbeitet dabei den 7-DoF Aktionsoutput des Modells und simuliert die resultierende Bewegung des Roboterarms. Dabei wurde bestätigt, dass die präzisierten Aktionen nicht zu einer Erfüllung der Aufgabe führten. Da für die Trainingsdatensätze gute Ergebnisse in der Offline-Evaluation erzeugt werden konnten, wurde mit der Online-Evaluation in den Simulationsumgebungen begonnen.

B. Online-Evaluation in der Simulationsumgebung

Eine Online-Evaluation verwendet, anders als die Offline-Evaluation, keine vorgegebenen Bilddaten, sondern einen Live-Kamera-Input und führt die Aktionen anschließend auch tatsächlich aus. In Echtzeit erhält das Modell den Bildinput und präzisiert Aktionen die anschließend ausgeführt werden [14]. Für die Trainingsdatensätze wurde das Modell in den Simulationsumgebungen *RLBench* und *Maniskill2* ausgeführt und Bilddaten in der Simulation generiert, die dem Modell als Input vorgegeben werden konnten.

1) *Qualitative Analyse:* Trotz der passenden Trajektorien, die in der Offline-Evaluation präzisiert wurden, lieferte die Online-Evaluation keine sinnvollen Bewegungen zur Erfüllung der Aufgaben. Eine beispielhafte Bewegung ist in Abbildung 7 dargestellt. Die Aufgabe die erfüllt werden sollte, lautete "Pick up the red cube and move it up". Das Modell war allerdings nicht einmal in der Lage den Würfel überhaupt zu erreichen. Der Grund hierfür könnte ein zu großer Unterschied zwischen den Bildern der Simulationsumgebung und den Bildern der echten Welt sein, auf denen das Modell trainiert wurde.

2) *Quantitative Analyse der Online-Evaluation:* Um eine quantitativer Analyse des Modellverhaltens durchzuführen und die Vorteile einer Evaluierung in einer Simulationsumgebung zu nutzen, wurde eine Messreihe für 100 Episoden aufgesetzt. Dabei wurden die von Maniskill speziell für diese Aufgabe konstruierte Dense Reward Funktion ausgelesen, welche ein Feedback in jedem Schritt ausgibt. Die Ausgabe der Reward Funktion ist höher, je näher der Roboter an die Erreichung des Ziels kommt (in diesem Fall "Pick up the cube and move it up."). Die Rewards wurden ausschließlich zur Bewertung der Qualität einer Aktion verwendet und nicht zum Training des Modells. Bei der Analyse der Rewards wurden 100 Episoden betrachtet, wobei jede Episode aus 100 Schritten bestand. Die vergebenen Rewards bewegen sich im Bereich zwischen 0 und 1, wobei ein höherer Reward darauf hinweist, dass die Bewegung des Roboters in die richtige Richtung geht. Ein höherer Reward in einem Schritt bedeutet, dass der

Roboter eine Aktion ausgeführt hat, die ihn effektiv näher an das Ziel, also an den roten Würfel bringt. Durch die Analyse dieser Rewards über die Zeit kann beurteilt werden, wie gut das Modell in der Lage ist, optimale Aktionen zu identifizieren und auszuführen, um seine Aufgabe erfolgreich zu bewältigen.

TABLE II
REWARDS FÜR 10 EPISODEN MIT JEWELLS 100 SCHRITTEN IN MANISKILL, GERUNDET AUF 4 NACHKOMMASTELLEN.

Episode	Avg. Reward	Max. Reward
1	0.0559	0.1418
2	0.0777	0.1052
3	0.0750	0.1353
4	0.0387	0.0796
5	0.0978	0.1362
6	0.0498	0.1329
7	0.0382	0.1107
8	0.0511	0.1162
9	0.1030	0.1492
10	0.0656	0.1425

In Tabelle II ist repräsentativ eine Ausgabe der Rewards für 10 Episoden dargestellt. Die komplette Tabelle mit den Ergebnissen für 100 Episoden ist im Anhang in Tabelle III zu finden. An den maximalen Rewards lässt sich erkennen, dass der Gripper in keiner der betrachteten Episoden annähernd dazu gekommen ist, das Ziel der Aufgabe zu erreichen. Die maximalen Rewards haben die untere Hälfte der möglichen Werte nie verlassen, eine Erfüllung der Aufgabe hätte zu diesem Zeitpunkt einen hohen Reward zur Folge gehabt. Die sehr niedrigen durchschnittlichen Rewards zeigen außerdem, dass ein Großteil der Aktionen zu keinerlei Annäherung an das Ziel führt.

3) *Zwischenfazit der Simulationsevaluation:* Die Evaluation des Modells ergab zwei wichtige Erkenntnisse. Erstens ist das Modell nicht in der Lage auf Datensätze zu generalisieren, auf denen es nicht trainiert wurde. Da dies sogar bei der Vorgabe von Offline-Trajektorien der Fall ist, ist auch nicht zu erwarten, dass das Modell in völlig unbekannten Umgebungen in der echten Welt in der Lage sein könnte, neue Aufgaben zu erfüllen. Daher wurde sich in der folgenden Evaluation am echten Roboter auf die Nachstellung von Umgebungen aus den Trainingsdaten fokussiert. Zweitens liegt potenziell eine hohe Relevanz der optischen Ähnlichkeit der realen Kamerabilder zu den Trainingsdaten vor. Daher sollte eine möglichst hohe Ähnlichkeit aller Faktoren bei der Nachstellung der Environments erzeugt werden.

VI. EVALUATION AUF EINEM REALEN ROBOTER

In diesem Kapitel wird die Implementierung des *RT-I-X* Modells auf dem Franka Panda Roboterarm untersucht. Das Ziel dieses Kapitels besteht darin, die Herausforderungen und Lösungen bei der Implementierung des *RT-I-X* Modells auf der gegebenen Hardware und in der Umgebung zu beleuchten. Dabei werden die Erkenntnisse aus der Simulationsevaluation einbezogen und tiefergehend untersucht.

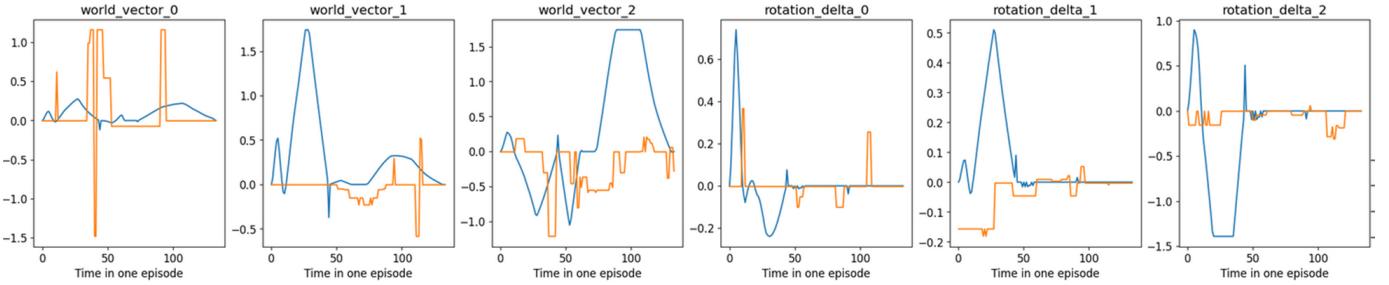


Fig. 6. *Maniskill v2 Offline Beobachtung: Ground Truth vs prädizierte Aktionen*



Fig. 7. *Maniskill v2 online test. Hier wird jedes fünfte Frame aus einer Episode gezeigt. Die Aufgabe lautet "Pick up the cube and move it up."*

A. Setup

Für die Kommunikation des Franka Panda Roboterarms wurde die Version 1 des Robot Operating System (ROS) verwendet. Die Architektur von ROS ermöglicht eine modulare Steuerung über verschiedene Nodes. Die Nodes für die Steuerung des Roboterarms, die Nodes für die Kamera als Repräsentation der Umgebung und die Nodes für das *RT-1-X* Modell wurden auf einem Rechner eingerichtet.

Die Implementierung des Modells und die Verwendung von relevanten Inputs und Outputs ist in Abbildung 8 dargestellt. Als Input in das *RT-1-X* Modell werden wie in [7] beschrieben ausschließlich eine natural-language-instruction und ein live Kamerainput verwendet. Das Modell verarbeitet diese Inputs und gibt anschließend eine Aktion in sieben Dimensionen (x, y, z, Rollen, Gieren, Neigen und Gripper) vor. Diese Aktion wird anschließend skaliert und an den Controller übermittelt. Der Controller sorgt für die Umsetzung der vorgegebenen Aktion durch den echten Franka Panda. Der aktuelle Zustand innerhalb des Beobachtungsbereichs der Kamera wird anschließend erneut an das Modell übergeben.

B. Plug & Play Evaluation

Zunächst sollte getestet werden, ob das Modell einfache Aufgaben aus einem der trainierten Datensätze ausführen kann, wenn sich der Beobachtungsbereich visuell nicht zu stark von der ursprünglichen Verteilung unterscheidet.

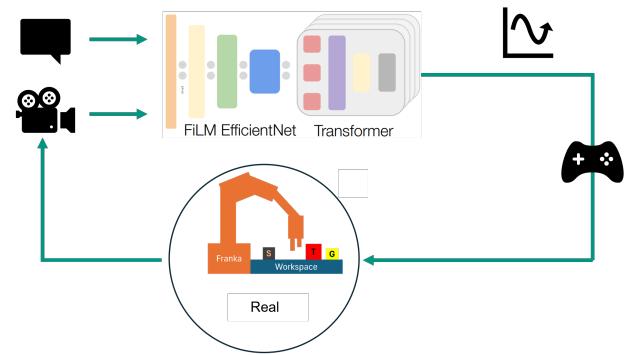


Fig. 8. *Implementierung des RT-1-X Modells auf einem lokalen Roboterarm*

Dazu wurde zunächst ein Datensatz ausgewählt, welcher geeignet ist um nachgestellt zu werden. Da das *RT-1-X* Modell laut [7] auf neun verschiedenen Datensätzen trainiert wurde (*RT-1*, *QT-Opt*, *Bridge*, *Taco Play*, *Jaco Play*, *Cable Routing*, *RoboTurk*, *NYU VINN*, *Austin VIOLA*), muss einer dieser Datensätze ausgewählt werden. Um die Unterschiede möglichst gering zu halten, sollte ein Datensatz gewählt werden, der den Roboterarm Franka Panda verwendet. Die Datensätze *Taco Play*, *Cable Routing* und *Austin VIOLA* erfüllen dieses Kriterium. Das dritte notwendige Kriterium stellt die Verwendung der Endeffektorposition für die Aktio-

nen dar. Nach Anwendung dieses Kriteriums blieben noch *Taco Play* und *Austin VIOLA* übrig. Als ergänzende Kriterien wurden die Nachstellbarkeit des Beobachtungsraums, sowie der Kameraausschnitt, dieser sollte möglichst den Roboterarm enthalten, aufgestellt. Diese wurden zunächst als zweitrangig betrachtet, da es nur eine geringe Auswahl an Datensätzen gab.

Um eine möglichst hohe Ähnlichkeit des Beobachtungsbereichs mit dem der ursprünglichen Verteilung zu erzielen, wurde zunächst eine Faktorenanalyse durchgeführt. Dabei wurden alle relevanten Faktoren, die Einfluss auf den Bildinput haben könnten, zusammengetragen.

- Kameraposition (relativ zur z-Achse)
- Kamerawinkel (relativ zur x-y-Ebene)
- Objekte im Workspace
- Objektposition
- NLP-Instruktion
- Lichtverhältnisse
- Hintergrund
- Environment im Workspace

Um sicherzustellen, dass die Ergebnisse vergleichbar sind, wurde für sowohl *Taco Play*, als auch *Austin VIOLA* das Setting aus den Datensätzen so genau wie möglich nachgestellt. Aufgrund der räumlichen Gegebenheiten am Institut waren insbesondere die Umgebung sowie der Hintergrund nur schwer reproduzierbar. Anschließend wurde die einfachste Sprachanweisung des Datensatzes vorgegeben: Für *Taco Play* lautete diese "Grasp the yellow block and turn it left", für *Austin VIOLA* "Arrange Plate and Fork".

Für beide Settings konnte kein sinnvolles Verhalten erzielt werden, weshalb anschließend eine systematische Fehleranalyse durchgeführt wurde um mögliche Fehlerquellen in der Implementierung auszuschließen.

C. Fehleranalyse

Für die Fehleranalyse wurden vier grundlegende mögliche Fehlerquellen identifiziert und systematisch überprüft. Das Vorgehen hierzu ist im Folgenden beschrieben.

1) Skalierung: Die Controller, die von den Forschungsgruppen des *RT-I-X* Modells verwendet wurden, sind nicht öffentlich zugänglich. Dadurch waren wichtige Details zur Ansteuerung und Skalierung des Roboterarms unbekannt. Die fehlenden Informationen über die genaue Funktionsweise des Controllers erschweren die Implementierung des *RT-I-X* Modells erheblich. Um die Aktionen des Modells möglichst genau an den lokal verwendeten Controller anzupassen, mussten daher passende Skalierungen ermittelt werden.

Dazu wurde zunächst das *RT-I-X* Modell vernachlässigt und dem Roboter Aktionen aus jeweils einer Episode von *Taco Play* und *Austin VIOLA* vorgegeben. Die ausgeführten Endeffektorpositionen wurden mit der Trajektorie der Datensatz-Episode verglichen und die Skalierung entsprechend so angepasst, dass der Unterschied zwischen den Trajektorien möglichst gering ist. Dazu wurde ein Gradient Decent-Verfahren durchgeführt, bei dem der Mean Squared Error (MSE) über jeweils drei Dimensionen gleichzeitig, x/y/z und Rollen/Gieren/Neigen, minimiert wurde. Das Ergebnis sind

jeweils zwei Skalierungsparameter pro Datensatz: einer für die World Vectors und einer für die Rotation Deltas.

- *Taco Play* - World Vector: 0.01151746, Rotation Delta: 0.01910615
- *Austin VIOLA* - World Vector: 111.12478128, Rotation Delta: 7.85031985

Es zeigt sich, dass sich die Skalierungen je nach Datensatz unterscheiden können. Dies hängt insbesondere von der jeweiligen Implementierung und Aktionsgröße der Datensätze ab. So sind die Aktionen in *Taco Play* gegenüber *Austin VIOLA* verhältnismäßig größer [15], [16]. Aus diesem Grund sollten die Aktionen für *Taco Play* vergrößert und für *Austin VIOLA* verkleinert werden. In Abbildung 9 sind für *Austin VIOLA* die Trajektorien des Datensatzes gegen die skalierten, real ausgeführten Trajektorien abgetragen. Da diese als ausreichend genau anzunehmen sind, wurde im Folgenden mit den berechneten Skalierungen gearbeitet und die Skalierung als mögliche Fehlerquelle ausgeschlossen. Es ist jedoch anzunehmen, dass mit aufwändigeren Verfahren bessere Skalierungen erzielt werden können.

2) Modellimplementierung: Als weitere mögliche Fehlerquelle wurde die Implementierung des *RT-I-X* Modells identifiziert. Daher wurden in diesem Schritt der Fehleranalyse die prädizierten Aktionen des Modells mit der Ground Truth einer Datensatztrajektorie abgeglichen. Dabei wurde analog zur Offline Evaluation der Simulationsevaluation vorgegangen. Es wurde der Bildinput aus einer Datensatz-Episode von *Taco Play* und *Austin VIOLA* vorgegeben und in das Modell eingespeist. Die Aktionen des Modells wurden anschließend mit den berechneten Skalierungen angepasst gegen die Datensatztrajektorie abgetragen. Dabei zeigten sich ähnliche Verläufe, bei denen es allerdings über den gesamten Verlauf zu Abweichungen kommt. Bei Betrachtung der tatsächlichen Bewegungen der Gripperposition in einer Simulationsumgebung wird deutlich, dass sich leichte statistische Abweichungen von der Trajektorie im Laufe der Zeit kumulieren können, was langfristig zu einem Terminalzustand führen kann. Dies ist vermutlich darauf zurückzuführen, dass der Bildinput nicht live ist und das Modell daher nicht auf abweichende Aktionen ausgleichend reagieren kann. Die Abweichungen sollten jedoch nicht automatisch als Fehler betrachtet werden, da Abweichungen von der Ground Truth durchaus zu erwarten sind. Bei der Eingabe von Live-Bildern sollte es darüber hinaus nicht mehr zu einer Akkumulation des Fehlers kommen, da hier die tatsächliche Position des Gripper als Bildeingabe übergeben wird.

In Abbildung 10 sind beispielhaft die prädizierten Trajektorien für die World Vectors von *Austin VIOLA* dargestellt. Hier sind die beschriebenen Abweichungen der Datensatz-Aktionen erkennbar. Da die prädizierten Aktionen des Modells mit offline Input zu sinnvollen Bewegungen führte, wurde die Implementierung des *RT-I-X* Modells als möglicher Fehler ausgeschlossen.

3) Controller: Da die prädizierten und skalierten Aktionen des Modells im vorherigen Schritt zu sinnvollen Bewe-

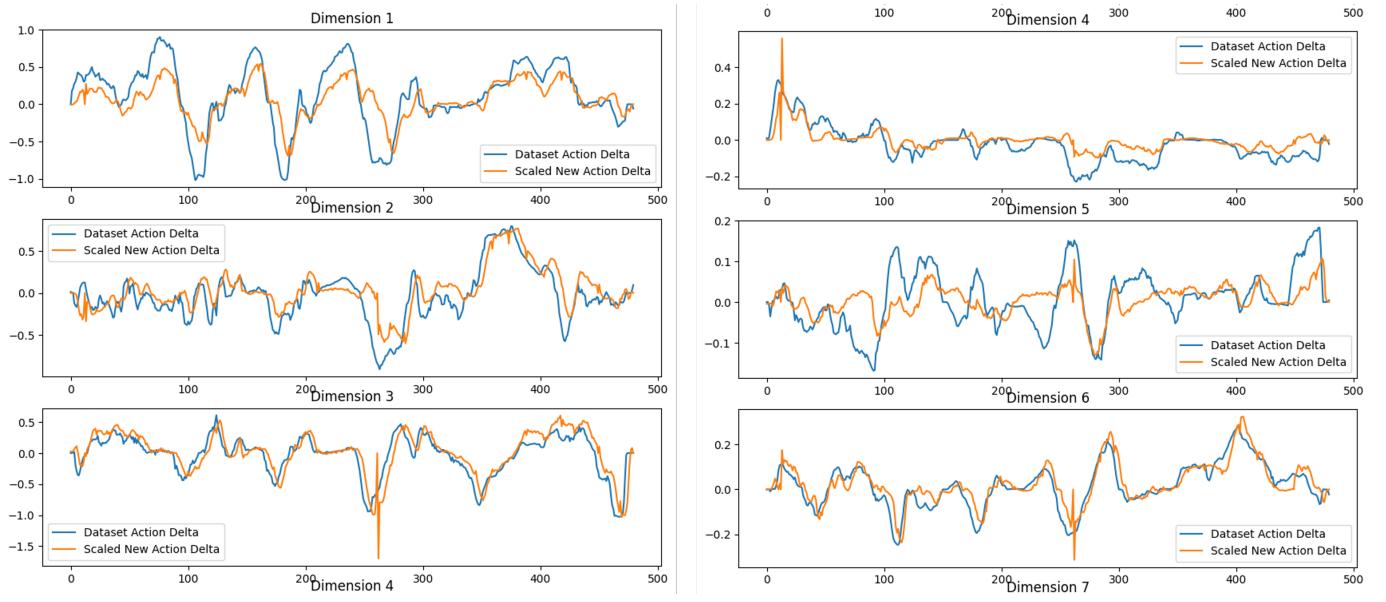


Fig. 9. Skalierte Aktionen (orange) und Datensatztrajektorie (blau) aus *Austin VIOLA*

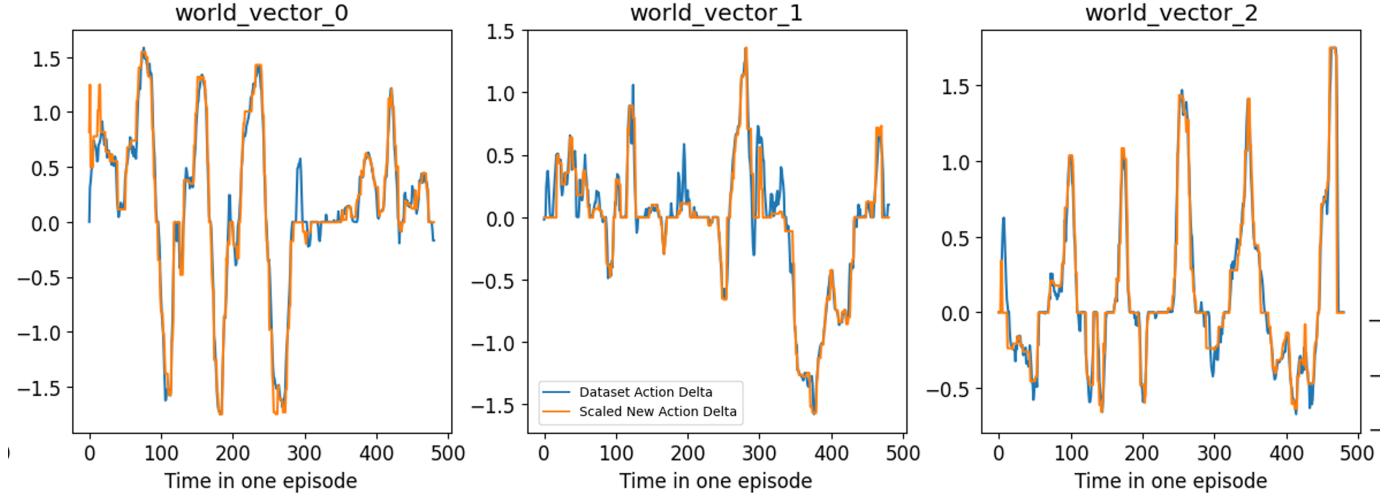


Fig. 10. Skalierte, prädizierte Aktionen (orange) und Datensatztrajektorie (blau) aus *Austin VIOLA* für die World Vector's

gungen führten, sollte in diesem Schritt der Fehleranalyse ausgeschlossen werden, dass Fehler zwischen Modell und Ausführung entstehen, also im Controller. Hierbei wurde einerseits die Definition der Achsen, sowie die Definition der Base-Koordinaten analysiert. In der Theorie sollten diese keinen Einfluss auf die Performance des Modells haben [17]. Um jedoch sicherzugehen, wurden die Koordinatensysteme an die Definitionen im *Austin VIOLA* Datensatz angepasst.

Eine weitere potenzielle Fehlerquelle stellt die Nutzung einer Impedanzregelung an Stelle einer Positionsregelung dar. Der Vorteil einer impedanzbasierten Regelung liegt in der höheren Robustheit und höheren Sicherheit im Umgang mit Objekten und Menschen, da eine dynamische Anpassung der Kräfte an Objekte im Environment, bei gleichzeitiger Zielerreicherung möglich ist. Dieser Vorteil bringt aber auch eine

höhere Komplexität und höhere absolute Ungenauigkeit mit sich, weshalb die Nutzung einer Positionskontrolle mit geringerer Wahrscheinlichkeit zu Fehlern führen könnte [18], [19]. Da lokal allerdings eine impedanzbasierte Regelung vorliegt, konnte diese potenzielle Fehlerquelle nicht ausgeschlossen werden.

4) Distribution Shift: Als letzte mögliche Fehlerquelle wurde Distribution Shift identifiziert. Distribution Shift beschreibt das Verhalten eines durch Machine Learning trainierten Modells, wenn es auf Daten angewendet wird, die sich in ihrer Verteilung von denen der Trainingsdaten unterscheiden. Dies kann zu einer abnehmenden Performance oder zum Versagen des Modells führen [20]. Somit bestärkt die Problematik des Distribution Shift die Notwendigkeit des ergänzenden Kriteriums "Nachstellbarkeit am Institut". Wie

bereits im Kapitel VI-B erläutert, war eine umfassendere Umsetzung aufgrund der begrenzten Auswahl an Datensätzen nur eingeschränkt möglich.

D. Online Evaluation

Nachdem alle potenziellen Fehlerquellen analysiert und nach Möglichkeit ausgeschlossen wurden, konnte ein weiterer Testlauf am Roboter durchgeführt werden. Dazu wurden erneut die Environments aus der Plug & Play-Evaluation nachgestellt, die gleichen Tasks vorgegeben und die berechneten Skalierungen verwendet. Im Gegensatz zu den Durchläufen in der Plug & Play-Evaluation waren die Aktionsgrößen und Bewegungen deutlich vergleichbar mit den Aktionen der jeweiligen Datensätze. Dies ist hauptsächlich auf die verbesserte Skalierung der Aktionen zurückzuführen. Trotz kontrollierter Bewegungen konnte jedoch keine signifikante Verbesserung bei der Zielerreichung festgestellt werden. Es ist anzunehmen, dass die visuellen Abweichungen des Environments im Vergleich zu den Trainingsdaten zu groß sind und der daraus resultierende Distribution Shift nicht durch generalisierendes Verhalten des Modells ausgeglichen werden kann. Dies wird unterstützt durch Beiträge der *RT-1-X* Mitarbeiter, die ebenfalls unterstreichen, dass das *RT-1-X* Modell ohne Feintuning nicht in der Lage sein wird, Out-of-Distribution-Einstellungen zu bewältigen [21]. Darüber hinaus wurden in [7] nur für das *RT-2-X* Modell Tests für die generalisierenden Fähigkeiten der Modelle durchgeführt. Für das *RT-1-X* Modell konnten somit keine generalisierenden Eigenschaften für visuell unterschiedliche Umgebungen nachgewiesen werden.

VII. ZUSAMMENFASSUNG UND AUSBLICK

Der RTX-Datensatz ist ein wichtiger Schritt in der Bereitstellung von vielfältiger Daten für das Training von aufgabenübergreifenden generalisierenden Robotikmodellen. Das *RT-1-X* Modell konnte dabei nachweisen, dass bereits verhältnismäßig kleine Multi-Task-Modelle in der Lage sind auf In-Distribution-Settings eine höhere Performance zu erreichen als die Single-Task trainierten Modelle. Darüber hinaus konnte das *RT-2-X* Modell zeigen, dass komplexere Modelle in der Lage sind auf unbekannte Aufgaben, Objekte und Umgebungen zu generalisieren.

Unsere Tests zur Implementierung des *RT-1-X* Modells in einer Simulationsumgebung sowie an einem Franka Panda haben gezeigt, dass das Modell ohne vorheriges Finetuning nicht in der Lage ist, visuell leicht abweichende Umgebungen zu generalisieren. Dieses Ergebnis wurde von Mitarbeitern des RTX-Papers bestätigt und steht auch im Einklang mit den Ergebnissen des Papers selbst [21], [7].

Um die Implementierung und Anwendungen von Modellen wie dem *RT-1-X* Modell in Zukunft zu vereinfachen, sollten Informationen wie beispielsweise die verwendeten Controller und Skalierungen zusammen mit dem Minimalbeispiel und den Datensätzen veröffentlicht werden. Zusätzlich könnte eine Standardisierung der Datensätze hilfreich sein. In allen

Datensätzen sollten beispielsweise relative statt absolute Endeffektorpositionen verwendet werden. Grundsätzlich stellt der *RT-1-X* Datensatz aber eine solide Grundlage für weitere Forschung in der Zukunft.

ACKNOWLEDGMENT

Wir bedanken uns bei Mohammd Karam Daaboul, Markus Fechner und Nikolai Polley für die kompetente Betreuung und Unterstützung bei unserem Projekt.

REFERENCES

- [1] OpenAI, J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman, D. Almeida, J. Alten Schmidt, S. Altman, S. Anadkat, R. Avila, I. Babuschkin, S. Balaji, V. Balcom, P. Baltescu, H. Bao, M. Bavarian, J. Belgum, I. Bello, J. Berdine, G. Bernadett-Shapiro, C. Berner, L. Bogdonoff, O. Boiko, M. Boyd, A.-L. Brakman, G. Brockman, T. Brooks, M. Brundage, K. Button, T. Cai, R. Campbell, A. Cann, B. Carey, C. Carlson, R. Carmichael, B. Chan, C. Chang, F. Chantzis, D. Chen, S. Chen, R. Chen, J. Chen, M. Chen, B. Chess, C. Cho, C. Chu, H. W. Chung, D. Cummings, J. Currier, Y. Dai, C. Decareaux, T. Degry, N. Deutsch, D. Deville, A. Dhar, D. Dohan, S. Dowling, S. Dunning, A. Ecoeff, A. Eleti, T. Eloundou, D. Farhi, L. Fedus, N. Felix, S. P. Fishman, J. Forte, I. Fulford, L. Gao, E. Georges, C. Gibson, V. Goel, T. Gogineni, G. Goh, R. Gontijo-Lopes, J. Gordon, M. Grafstein, S. Gray, R. Greene, J. Gross, S. S. Gu, Y. Guo, C. Hallacy, J. Han, J. Harris, Y. He, M. Heaton, J. Heidecke, C. Hesse, A. Hickey, W. Hickey, P. Hoeschele, B. Houghton, K. Hsu, S. Hu, X. Hu, J. Huizinga, S. Jain, S. Jain, J. Jang, A. Jiang, R. Jiang, H. Jin, D. Jin, S. Jomoto, B. Jonn, H. Jun, T. Kaftan, Łukasz Kaiser, A. Kamali, I. Kanitscheider, N. S. Keskar, T. Khan, L. Kilpatrick, J. W. Kim, C. Kim, Y. Kim, J. H. Kirchner, J. Kirov, M. Knight, D. Kokotajlo, Łukasz Kondraciuk, A. Kondrich, A. Konstantinidis, K. Kosić, G. Krueger, V. Kuo, M. Lampe, I. Lan, T. Lee, J. Leike, J. Leung, D. Levy, C. M. Li, R. Lim, M. Lin, S. Lin, M. Litwin, T. Lopez, R. Lowe, P. Lue, A. Makanju, K. Malfacini, S. Manning, T. Markov, Y. Markovski, B. Martin, K. Mayer, A. Mayne, B. McGrew, S. M. McKinney, C. McLeavy, P. McMillan, J. McNeil, D. Medina, A. Mehta, J. Menick, L. Metz, A. Mishchenko, P. Mishkin, V. Monaco, E. Morikawa, D. Mossing, T. Mu, M. Murati, O. Murk, D. Mély, A. Nair, R. Nakano, R. Nayak, A. Neelakantan, R. Ngo, H. Noh, L. Ouyang, C. O'Keefe, J. Pachocki, A. Paino, J. Palermo, A. Pantuliano, G. Parascandolo, J. Parish, E. Parparita, A. Passos, M. Pavlov, A. Peng, A. Perelman, F. de Avila Belbute Peres, M. Petrov, H. P. de Oliveira Pinto, Michael, Pokorny, M. Pokrass, V. H. Pong, T. Powell, A. Power, B. Power, E. Proehl, R. Puri, A. Radford, J. Rae, A. Ramesh, C. Raymond, F. Real, K. Rimbach, C. Ross, B. Rotstetd, H. Roussez, N. Ryder, M. Saltarelli, T. Sanders, S. Santurkar, G. Sastry, H. Schmidt, D. Schnurr, J. Schulman, D. Selsam, K. Sheppard, T. Sherbakov, J. Shieh, S. Shoker, P. Shyam, S. Sidor, E. Sigler, M. Simens, J. Sitkin, K. Slama, I. Sohl, B. Sokolowsky, Y. Song, N. Staudacher, F. P. Such, N. Summers, I. Sutskever, J. Tang, N. Tezak, M. B. Thompson, P. Tillet, A. Tootoonchian, E. Tseng, P. Tuggle, N. Turley, J. Tworek, J. F. C. Uribe, A. Vallone, A. Vijayvergiya, C. Voss, C. Wainwright, J. J. Wang, A. Wang, B. Wang, J. Ward, J. Wei, C. Weimann, A. Welihinda, P. Welinder, J. Weng, L. Weng, M. Wiethoff, D. Willner, C. Winter, S. Wolrich, H. Wong, L. Workman, S. Wu, J. Wu, M. Wu, K. Xiao, T. Xu, S. Yoo, K. Yu, Q. Yuan, W. Zaremba, R. Zellers, C. Zhang, M. Zhang, S. Zhao, T. Zheng, J. Zhuang, W. Zhuk, and B. Zoph, "Gpt-4 technical report," 2024.
- [2] G. Team, R. Anil, S. Borgeaud, Y. Wu, J.-B. Alayrac, J. Yu, R. Soricu, J. Schalkwyk, A. M. Dai, A. Hauth, K. Millican, D. Silver, S. Petrov, M. Johnson, I. Antonoglou, J. Schriftwieser, A. Glaese, J. Chen, E. Pitler, T. Lillicrap, A. Lazaridou, O. Firat, J. Molloy, M. Isard, P. R. Barham, T. Hennigan, B. Lee, F. Viola, M. Reynolds, Y. Xu, R. Doherty, E. Collins, C. Meyer, E. Rutherford, E. Moreira, K. Ayoub, M. Goel, G. Tucker, E. Piqueras, M. Krikun, I. Barr, N. Savinov, I. Danihelka, B. Roelofs, A. White, A. Andreassen, T. von Glehn, L. Yagati, M. Kazemi, L. Gonzalez, M. Khalman, J. Sygnowski, A. Frechette, C. Smith, L. Culp, L. Proleev, Y. Luan, X. Chen, J. Lottes, N. Schucher, F. Lebron, A. Rrustemi, N. Clay, P. Crone, T. Kociský, J. Zhao, B. Perz, D. Yu, H. Howard, A. Bloniarz, J. W. Rae, H. Lu,

L. Sifre, M. Maggioni, F. Alcober, D. Garrette, M. Barnes, S. Thakoor, J. Austin, G. Barth-Maron, W. Wong, R. Joshi, R. Chaabouni, D. Fatihia, A. Ahuja, R. Liu, Y. Li, S. Cogan, J. Chen, C. Jia, C. Gu, Q. Zhang, J. Grimstad, A. J. Hartman, M. Chadwick, G. S. Tomar, X. Garcia, E. Senter, E. Taropa, T. S. Pillai, J. Devlin, M. Laskin, D. de Las Casas, D. Valter, C. Tao, L. Blanco, A. P. Badia, D. Reitter, M. Chen, J. Brennan, C. Rivera, S. Brin, S. Iqbal, G. Surita, J. Labanowski, A. Rao, S. Winkler, E. Parisotto, Y. Gu, K. Olszewska, Y. Zhang, R. Addanki, A. Miech, A. Louis, L. E. Shafeey, D. Teplyashin, G. Brown, E. Catt, N. Attaluri, J. Balaguer, J. Xiang, P. Wang, Z. Ashwood, A. Briukhov, A. Webson, S. Ganapathy, S. Sanghavi, A. Kannan, M.-W. Chang, A. Stjerngren, J. Djolonga, Y. Sun, A. Bapna, M. Aitchison, P. Pejman, H. Michalewski, T. Yu, C. Wang, J. Love, J. Ahn, D. Bloxwich, K. Han, P. Humphreys, T. Sellam, J. Bradbury, V. Godbole, S. Samangooei, B. Damoc, A. Kaskasoli, S. M. R. Arnold, V. Vasudevan, S. Agrawal, J. Riesa, D. Lepikhin, R. Tanburn, S. Srinivasan, H. Lim, S. Hodkinson, P. Shyam, J. Ferret, S. Hand, A. Garg, T. L. Paine, J. Li, Y. Li, M. Giang, A. Neitz, Z. Abbas, S. York, M. Reid, E. Cole, A. Chowdhery, D. Das, D. Rogozinska, V. Nikolaev, P. Sprechmann, Z. Nado, L. Zilka, F. Prost, L. He, M. Monteiro, G. Mishra, C. Welty, J. Newlan, D. Jia, M. Allamanis, C. H. Hu, R. de Liedekerke, J. Gilmer, C. Saroufim, S. Rijhwani, S. Hou, D. Shrivastava, A. Baddepudi, A. Goldin, A. Ozturel, A. Cassirer, Y. Xu, D. Sohn, D. Sachan, R. K. Amplayo, C. Swanson, D. Petrova, S. Narayan, A. Guez, S. Brahma, J. Landon, M. Patel, R. Zhao, K. Villela, L. Wang, W. Jia, M. Rahtz, M. Giménez, L. Yeung, H. Lin, J. Keeling, P. Georgiev, D. Mincu, B. Wu, S. Haykal, R. Saputro, K. Vodrahalli, J. Qin, Z. Cankara, A. Sharma, N. Fernando, W. Hawkins, B. Neyshabur, S. Kim, A. Hutter, P. Agrawal, A. Castro-Ros, G. van den Driessche, T. Wang, F. Yang, S. yiin Chang, P. Komarek, R. McIlroy, M. Lučić, G. Zhang, W. Farhan, M. Sharman, P. Natsev, P. Michel, Y. Cheng, Y. Bansal, S. Qiao, K. Cao, S. Shakeri, C. Butterfield, J. Chung, P. K. Rubenstein, S. Agrawal, A. Mensch, K. Soparkar, K. Lenc, T. Chung, A. Pope, L. Maggiore, J. Kay, P. Jhakra, S. Wang, J. Maynez, M. Phuong, T. Tobin, A. Tacchetti, M. Trebacz, K. Robinson, Y. Katariya, S. Riedel, P. Bailey, K. Xiao, N. Ghelani, L. Arroyo, A. Slone, N. Houlsby, X. Xiong, Z. Yang, E. Gribovskaya, J. Adler, M. Wirth, L. Lee, M. Li, T. Kagohara, J. Pavagadhi, S. Bridgers, A. Bortsova, S. Ghemawat, Z. Ahmed, T. Liu, R. Powell, V. Bolina, M. Inuma, P. Zablotskaia, J. Besley, D.-W. Chung, T. Dozat, R. Comanescu, X. Si, J. Greer, G. Su, M. Polacek, R. L. Kaufman, S. Tokumine, H. Hu, E. Buchatskaya, Y. Miao, M. Elhawaty, A. Siddhant, N. Tomasev, J. Xing, C. Greer, H. Miller, S. Ashraf, A. Roy, Z. Zhang, A. Ma, A. Filos, M. Besta, R. Blevins, T. Klimenko, C.-K. Yeh, S. Changpinyo, J. Mu, O. Chang, M. Pajarskas, C. Muir, V. Cohen, C. L. Lan, K. Haridasan, A. Marathe, S. Hansen, S. Douglas, R. Samuel, M. Wang, S. Austin, C. Lan, J. Jiang, J. Chiu, J. A. Lorenzo, L. L. Sjölund, S. Cevey, Z. Gleicher, T. Avrahami, A. Boral, H. Srinivasan, V. Selo, R. May, K. Aisopos, L. Hussenot, L. B. Soares, K. Baumli, M. B. Chang, A. Recasens, B. Caine, A. Pritzel, F. Pavetic, F. Pardo, A. Gergely, J. Frye, V. Ramasesh, D. Horgan, K. Badola, N. Kassner, S. Roy, E. Dyer, V. Campos, A. Tomala, Y. Tang, D. E. Badawy, E. White, B. Mustafa, O. Lang, A. Jindal, S. Vikram, Z. Gong, S. Caelles, R. Hemsley, G. Thornton, F. Feng, W. Stokowiec, C. Zheng, P. Thacker, Çağlar Ünlü, Z. Zhang, M. Saleh, J. Svensson, M. Bileschi, P. Patil, A. Anand, R. Ring, K. Tsilihas, A. Vezer, M. Selvi, T. Shevlane, M. Rodriguez, T. Kwiatkowski, S. Daruki, K. Rong, A. Dafoe, N. Fitzgerald, K. Gu-Lemberg, M. Khan, L. A. Hendricks, M. Pellat, V. Feinberg, J. Cobon-Kerr, T. Sainath, M. Rauh, S. H. Hashemi, R. Ives, Y. Hasson, Y. Li, E. Noland, Y. Cao, N. Byrd, L. Hou, Q. Wang, T. Sottiaux, M. Paganini, J.-B. Lespiau, A. Moufarek, S. Hassan, K. Shivakumar, J. van Amersfoort, A. Mandhane, P. Joshi, A. Goyal, M. Tung, A. Brock, H. Sheahan, V. Misra, C. Li, N. Rakic̄ević, M. Dehghani, F. Liu, S. Mittal, J. Oh, S. Noury, E. Sezener, F. Huot, M. Lamm, N. D. Cao, C. Chen, G. Elsayed, E. Chi, M. Mahdief, I. Tenney, N. Hua, I. Petrychenko, P. Kane, D. Scandinaro, R. Jain, J. Uesato, R. Datta, A. Sadovsky, O. Bunyan, D. Rabiej, S. Wu, J. Zhang, G. Vasudevan, E. Leurent, M. Alnahlawi, I. Georgescu, N. Wei, I. Zheng, B. Chan, P. G. Rabinovitch, P. Stanczyk, Y. Zhang, D. Steiner, S. Naskar, M. Azzam, M. Johnson, A. Paszke, C.-C. Chiu, J. S. Elias, A. Mohiuddin, F. Muhammad, J. Miao, A. Lee, N. Vieillard, S. Potluri, J. Park, E. Davoodi, J. Zhang, J. Stanway, D. Garmon, A. Karmarkar, Z. Dong, J. Lee, A. Kumar, L. Zhou, J. Evens, W. Isaac, Z. Chen, J. Jia, A. Levskaya, Z. Zhu, C. Gorgolewski, P. Grabowski, Y. Mao, A. Magni, K. Yao, J. Snaider, N. Casagrande, P. Suganthan, E. Palmer, G. Irving, E. Loper, M. Faruqui, I. Arkatkar, N. Chen, I. Shafran, M. Fink, A. Castaño, I. Giannoumis, W. Kim, M. Rybiński, A. Sreevatsa, J. Prendki, D. Soergel, A. Goedeckemeyer, W. Gierke, M. Jafari, M. Gaba, J. Wiesner, D. G. Wright, Y. Wei, H. Vashishtha, Y. Kulizhskaya, J. Hoover, M. Le, L. Li, C. Iwuanyanwu, L. Liu, K. Ramirez, A. Khorlin, A. Cui, T. LIN, M. Georgiev, M. Wu, R. Aguilar, K. Pallo, A. Chakladar, A. Repina, X. Wu, T. van der Weide, P. Ponnappalli, C. Kaplan, J. Simsa, S. Li, O. Dousse, F. Yang, J. Piper, N. Ie, M. Lui, R. Pasumarthi, N. Lintz, A. Vijayakumar, L. N. Thiet, D. Andor, P. Valenzuela, C. Paduraru, D. Peng, K. Lee, S. Zhang, S. Greene, D. D. Nguyen, P. Kurylowicz, S. Velury, S. Krause, C. Hardin, L. Dixon, L. Janzer, K. Choo, Z. Feng, B. Zhang, A. Singhal, T. Latkar, M. Zhang, Q. Le, E. A. Abellan, D. Du, D. McKinnon, N. Antropova, T. Bolukbasi, O. Keller, D. Reid, D. Finchelstein, M. A. Raad, R. Crocker, P. Hawkins, R. Dadashi, C. Gaffney, S. Lall, K. Franko, E. Filonov, A. Bulanova, R. Leblond, V. Yadav, S. Chung, H. Askham, L. C. Cobo, K. Xu, F. Fischer, J. Xu, C. Sorokin, C. Alberti, C.-C. Lin, C. Evans, H. Zhou, A. Dimitriev, H. Forbes, D. Banarse, Z. Tung, J. Liu, M. Omernick, C. Bishop, C. Kumar, R. Sterneck, R. Foley, R. Jain, S. Mishra, J. Xia, T. Bos, G. Cideron, E. Amid, F. Piccinno, X. Wang, P. Banzal, P. Gurita, H. Noga, P. Shah, D. J. Mankowitz, A. Polozov, N. Kushman, V. Krakovna, S. Brown, M. Bateni, D. Duan, V. Firoiu, M. Thotakuri, T. Natan, A. Mohananey, M. Geist, S. Mudgal, S. Girgin, H. Li, J. Ye, O. Roval, R. Tojo, M. Kwong, J. Lee-Thorp, C. Yew, Q. Yuan, S. Bagri, D. Sinopalnikov, S. Ramos, J. Mellor, A. Sharma, A. Severyn, J. Lai, K. Wu, H.-T. Cheng, D. Miller, N. Sonnerat, D. Vnukov, R. Greig, J. Beattie, E. Caveness, L. Bai, J. Eisenschlos, A. Korchemniy, T. Tsai, M. Jasarevic, W. Kong, P. Dao, Z. Zheng, F. Liu, F. Yang, R. Zhu, M. Geller, T. H. Teh, J. Sanmiya, E. Gladchenko, N. Trdin, A. Sozanschi, D. Toyama, E. Rosen, S. Tavakkol, L. Xue, C. Elkind, O. Woodman, J. Carpenter, G. Papamakarios, R. Kemp, S. Kafe, T. Grunina, R. Sinha, A. Talbert, A. Goyal, D. Wu, D. Owusu-Afriyie, C. Du, C. Thornton, J. Pont-Tuset, P. Narayana, J. Li, S. Fatehi, J. Wieting, O. Ajmeri, B. Urias, T. Zhu, Y. Ko, L. Knight, A. Héliou, N. Niu, S. Gu, C. Pang, D. Tran, Y. Li, N. Levine, A. Stolovich, N. Kalb, R. Santamaría-Fernandez, S. Goenka, W. Yustalim, R. Strudel, A. Elqursh, B. Lakshminarayanan, C. Deck, S. Upadhyay, H. Lee, M. Dusenberry, Z. Li, X. Wang, K. Levin, R. Hoffmann, D. Holtmann-Rice, O. Bachem, S. Yue, S. Arora, E. Malmi, D. Mirylenka, Q. Tan, C. Koh, S. H. Yeganeh, S. Pöder, S. Zheng, F. Pongetti, M. Tariq, Y. Sun, L. Ionita, M. Seyedhosseini, P. Tafti, R. Kotikalapudi, Z. Liu, A. Gulati, J. Liu, X. Ye, B. Chrzaszcz, L. Wang, N. Sethi, T. Li, B. Brown, S. Singh, W. Fan, A. Parisi, J. Stanton, C. Kuang, V. Koverkathu, C. A. Choquette-Choo, Y. Li, T. Lu, A. Ittycheriah, P. Shroff, P. Sun, M. Varadarajan, S. Bahargam, R. Willoughby, D. Gaddy, I. Dasgupta, G. Desjardins, M. Cornero, B. Robenek, B. Mittal, B. Albrecht, A. Shenoy, F. Moiseev, H. Jacobsson, A. Ghaffarkhah, M. Rivière, A. Walton, C. Crepy, A. Parish, Y. Liu, Z. Zhou, C. Farabet, C. Radebaugh, P. Srinivasan, C. van der Salm, A. Fidjeland, S. Scellato, E. Latorre-Chimoto, H. Klimczak-Plucińska, D. Bridson, D. de Cesare, T. Hudson, P. Mendolicchio, L. Walker, A. Morris, I. Penchev, M. Mauger, A. Guseynov, A. Reid, S. Odoom, L. Loher, V. Cotrutz, M. Yenugula, D. Grawe, A. Petrushina, T. Duerig, A. Sanchez, S. Yadlowsky, A. Shen, A. Globerson, A. Kurzrok, L. Webb, S. Dua, D. Li, P. Lahoti, S. Bhupatiraju, D. Hurt, H. Qureshi, A. Agarwal, T. Shani, M. Eyal, A. Khare, S. R. Belle, L. Wang, C. Tekur, M. S. Kale, J. Wei, R. Sang, B. Saeta, T. Liechty, Y. Sun, Y. Zhao, S. Lee, P. Nayak, D. Fritz, M. R. Vuyyuru, J. Aslanides, N. Vyas, M. Wicke, X. Ma, T. Bilal, E. Eltyshev, D. Balle, N. Martin, H. Cate, J. Manyika, K. Amiri, Y. Kim, X. Xiong, K. Kang, F. Luisier, N. Tripuraneni, D. Madras, M. Guo, A. Waters, O. Wang, J. Ainslie, J. Baldridge, H. Zhang, G. Pruthi, J. Bauer, F. Yang, R. Mansour, J. Gelman, Y. Xu, G. Polovets, J. Liu, H. Cai, W. Chen, X. Sheng, E. Xue, S. Ozair, A. Yu, C. Angermueller, X. Li, W. Wang, J. Wiesinger, E. Koukoumidis, Y. Tian, A. Iyer, M. Gurumurthy, M. Goldenson, P. Shah, M. Blake, H. Yu, A. Urbanowicz, J. Palomaki, C. Fernando, K. Brooks, K. Durden, H. Mehta, N. Momchev, E. Rahimtoroghi, M. Georgaki, A. Raul, S. Ruder, M. Redshaw, J. Lee, K. Jalan, D. Li, G. Perng, B. Hechtmann, P. Schuh, M. Nasr, M. Chen, K. Milan, V. Mikulik, T. Strohman, J. Franco, T. Green, D. Hassabis, K. Kavukcuoglu, J. Dean, and O. Vinyals, “Gemini: A family of highly capable multimodal models,” 2023.

[3] Anthropic. (2024) The claude 3 model family: Opus, sonnet, haiku. Accessed: 2024-03-28. [Online]. Available: <https://www.anthropic.com/news/claude-3-family>

- [4] T. Brooks, B. Peebles, C. Holmes, W. DePue, Y. Guo, L. Jing, D. Schnurr, J. Taylor, T. Luhman, E. Luhman, C. Ng, R. Wang, and A. Ramesh, “Video generation models as world simulators,” 2024. [Online]. Available: <https://openai.com/research/video-generation-models-as-world-simulators>
- [5] J. Frieling, “Towards a unified robotics model: Exploring ways to learn from multi-embodiment data,” 2024.
- [6] R. Firooz, J. Tucker, S. Tian, A. Majumdar, J. Sun, W. Liu, Y. Zhu, S. Song, A. Kapoor, K. Hausman *et al.*, “Foundation models in robotics: Applications, challenges, and the future,” *arXiv preprint arXiv:2312.07843*, 2023.
- [7] E. Collaboration, A. Padalkar, A. Pooley, A. Mandlekar, A. Jain, A. Tung, A. Bewley, A. Herzog, A. Irpan, A. Khazatsky, A. Rai, A. Singh, A. Garg, A. Brohan, A. Raffin, A. Wahid, B. Burgess-Limerick, B. Kim, B. Schölkopf, B. Ichter, C. Lu, C. Xu, C. Finn, C. Xu, C. Chi, C. Huang, C. Chan, C. Pan, C. Fu, C. Devin, D. Driess, D. Pathak, D. Shah, D. Büchler, D. Kalashnikov, D. Sadigh, E. Johns, F. Ceola, F. Xia, F. Stulp, G. Zhou, G. S. Sukhatme, G. Salhotra, G. Yan, G. Schiavi, G. Kahn, H. Su, H.-S. Fang, H. Shi, H. B. Amor, H. I. Christensen, H. Furuta, H. Walke, H. Fang, I. Mordatch, I. Radosavovic, I. Leal, J. Liang, J. Abou-Chakra, J. Kim, J. Peters, J. Schneider, J. Hsu, J. Bohg, J. Bingham, J. Wu, J. Wu, J. Luo, J. Gu, J. Tan, J. Oh, J. Malik, J. Booher, J. Tompson, J. Yang, J. J. Lim, J. Silvério, J. Han, K. Rao, K. Pertsch, K. Hausman, K. Go, K. Gopalakrishnan, K. Goldberg, K. Byrne, K. Oslund, K. Kawaharazuka, K. Zhang, K. Rana, K. Srinivasan, L. Y. Chen, L. Pinto, L. Fei-Fei, L. Tan, L. Ott, L. Lee, M. Tomizuka, M. Spero, M. Du, M. Ahn, M. Zhang, M. Ding, M. K. Srirama, M. Sharma, M. J. Kim, N. Kanazawa, N. Hansen, N. Heess, N. J. Joshi, N. Suenderhauf, N. D. Palo, N. M. M. Shafullah, O. Mees, O. Kroemer, P. R. Sanketi, P. Wohlhart, P. Xu, P. Sermanet, P. Sundaresan, Q. Vuong, R. Rafailov, R. Tian, R. Doshi, R. Martín-Martín, R. Mendonca, R. Shah, R. Hoque, R. Julian, S. Bustamante, S. Kirmani, S. Levine, S. Moore, S. Bahl, S. Dass, S. Sonawani, S. Song, S. Xu, S. Haldar, S. Adebola, S. Guist, S. Nasiriany, S. Schaal, S. Welker, S. Tian, S. Dasari, S. Belkhale, T. Osa, T. Harada, T. Matsushima, T. Xiao, T. Yu, T. Ding, T. Davchev, T. Z. Zhao, T. Armstrong, T. Darrell, V. Jain, V. Vanhoucke, W. Zhan, W. Zhou, W. Burgard, X. Chen, X. Wang, X. Zhu, X. Li, Y. Lu, Y. Chebotar, Y. Zhou, Y. Zhu, Y. Xu, Y. Wang, Y. Bisk, Y. Cho, Y. Lee, Y. Cui, Y.-H. Wu, Y. Tang, Y. Zhu, Y. Li, Y. Iwasawa, Y. Matsuo, Z. Xu, and Z. J. Cui, “Open x-embodiment: Robotic learning datasets and rt-x models,” 2023.
- [8] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, J. Dabis, C. Finn, K. Gopalakrishnan, K. Hausman, A. Herzog, J. Hsu, J. Ibarz, B. Ichter, A. Irpan, T. Jackson, S. Jesmonth, N. J. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, K.-H. Lee, S. Levine, Y. Lu, U. Malla, D. Manjunath, I. Mordatch, O. Nachum, C. Parada, J. Peralta, E. Perez, K. Pertsch, J. Quiambao, K. Rao, M. Ryoo, G. Salazar, P. Sanketi, K. Sayed, J. Singh, S. Sontakke, A. Stone, C. Tan, H. Tran, V. Vanhoucke, S. Vega, Q. Vuong, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, “Rt-1: Robotics transformer for real-world control at scale,” 2023.
- [9] A. Brohan, N. Brown, J. Carbajal, Y. Chebotar, X. Chen, K. Choromanski, T. Ding, D. Driess, A. Dubey, C. Finn, P. Florence, C. Fu, M. G. Arenas, K. Gopalakrishnan, K. Han, K. Hausman, A. Herzog, J. Hsu, B. Ichter, A. Irpan, N. Joshi, R. Julian, D. Kalashnikov, Y. Kuang, I. Leal, L. Lee, T.-W. E. Lee, S. Levine, Y. Lu, H. Michalewski, I. Mordatch, K. Pertsch, K. Rao, K. Reymann, M. Ryoo, G. Salazar, P. Sanketi, P. Sermanet, J. Singh, A. Singh, R. Soricut, H. Tran, V. Vanhoucke, Q. Vuong, A. Wahid, S. Welker, P. Wohlhart, J. Wu, F. Xia, T. Xiao, P. Xu, S. Xu, T. Yu, and B. Zitkovich, “Rt-2: Vision-language-action models transfer web knowledge to robotic control,” 2023.
- [10] Octo Model Team, D. Ghosh, H. Walke, K. Pertsch, K. Black, O. Mees, S. Dasari, J. Hejna, C. Xu, J. Luo, T. Kreiman, Y. Tan, D. Sadigh, C. Finn, and S. Levine, “Octo: An open-source generalist robot policy,” <https://octo-models.github.io>, 2023.
- [11] E. Perez, F. Strub, H. de Vries, V. Dumoulin, and A. Courville, “Film: Visual reasoning with a general conditioning layer,” 2017.
- [12] M. Tan and Q. V. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” 2020.
- [13] D. Cer, Y. Yang, S. yi Kong, N. Hua, N. Limtiaco, R. S. John, N. Constant, M. Guajardo-Cespedes, S. Yuan, C. Tar, Y.-H. Sung, B. Strope, and R. Kurzweil, “Universal sentence encoder,” 2018.
- [14] A. Zheng, *Evaluating machine learning models: a beginner’s guide to key concepts and pitfalls*. O’Reilly Media, 2015.
- [15] O. Mees. (2023) Kaggle. Accessed: 2024-03-20. [Online]. Available: <https://www.kaggle.com/datasets/oiermees/taco-robot>
- [16] Y. Zhu, A. Joshi, P. Stone, and Y. Zhu. (2023) Github. Accessed: 2024-03-20. [Online]. Available: <https://github.com/UT-Austin-RPL/VIOLA>
- [17] K. Pertsch. (2024) Github. Accessed: 2024-03-20. [Online]. Available: https://github.com/google-deepmind/open_x_embodiment/issues/48
- [18] A. Albu-Schäffer, C. Ott, and G. Hirzinger, “A unified passivity-based control framework for position, torque and impedance control of flexible joint robots,” *The international journal of robotics research*, vol. 26, no. 1, pp. 23–39, 2007.
- [19] A. Albu-Schäffer, S. Haddadin, C. Ott, A. Stemmer, T. Wimböck, and G. Hirzinger, “The dlr lightweight robot: design and control concepts for robots in human environments,” *Industrial Robot: an international journal*, vol. 34, no. 5, pp. 376–385, 2007.
- [20] O. Wiles, S. Gowal, F. Stimberg, S. Alvise-Rebuffi, I. Ktena, K. Dvijotham, and T. Cemgil, “A fine-grained analysis on distribution shift,” 2021.
- [21] K. Pertsch. (2024) Github. Accessed: 2024-03-20. [Online]. Available: https://github.com/google-deepmind/open_x_embodiment/issues/23

VIII. APPENDIX

TABLE III
REWARDS FÜR 100 EPISODEN MIT JEWELLS 100 SCHRITTEN IN DER
MANISKILL SIMULATIONSBEWEGUNG. DIE AUFGABE IST "PICK UP THE
CUBE AND MOVE IT UP."

Episode	Cumulative Reward	Average Reward	Maximum Reward
1	17.678218016181038	0.08839109008090519	0.14270701715201461
2	9.5253842638336948	0.04762692134168474	0.106570457009682
3	12.358358025494486	0.06179179012747243	0.1459412012186013
4	11.650946471539454	0.05825473235769727	0.07964728622443859
5	15.267232210591645	0.07633616105295822	0.13617445434923292
6	13.09621622588031	0.065481081112940156	0.14302844902645034
7	30.1709835765648	0.15085491788282424	0.24132397848593376
8	24.773486342508523	0.12386743171254261	0.20994818584786996
9	11.91208379396406	0.05956401896982203	0.1484518654038813
10	41.11804697502363	0.20559023487511816	0.3186995384290974
11	16.595913598283587	0.0829956799141794	0.1135164854948934
12	15.79396422762434	0.07896952113681217	0.1294157847392031
13	11.8312434382672079	0.05917121741336039	0.1321116281778438
14	13.695132081961397	0.06847566040980699	0.1468054962958022
15	19.485104856629366	0.09742597428314684	0.14813418570147097
16	15.187409742974783	0.0793704871487392	0.150239529879069
17	27.49743007427207	0.13748715035213604	0.20372055398093503
18	10.952005389045901	0.0547600269452295	0.144750534767462523
19	19.147347832642698	0.09573673916321349	0.11469559097179621
20	24.860931132160008	0.12430465566080004	0.15299550415534321
21	25.59394507755748	0.1279697253877874	0.15962454307475296
22	13.06523652533527	0.06532618262667636	0.12953568286718545
23	14.978033301811747	0.07489016650905873	0.16598438365194784
24	18.641098894166277	0.0937054947083139	0.1451709593728293
25	10.75077672083019	0.053753883604150954	0.11946552101226832
26	16.70945949163602	0.0835472974583181	0.16519709628931561
27	33.70938958602323	0.16854694793011615	0.2204318252078646
28	28.388206859591225	0.149194103429795613	0.1588495363031119
29	20.632873366888795	0.10316436683444398	0.15898611177002986
30	15.899921603751212	0.07949960801875605	0.11789228696147333
31	20.16743802668642	0.10083719013543022	0.14248254069416904
32	17.872846524264123	0.08936423262132061	0.12221640749096065
33	16.609436971571245	0.08304718485785623	0.12771112133391072
34	12.1722363603170521	0.06086181515852604	0.1279546060607031
35	7.153794174340387	0.03576897087170194	0.104126966452811
36	14.68895340265269	0.07344476701326345	0.14794650363911424
37	21.32380915100244	0.106641545750122	0.1504894856139068
38	10.754977529579005	0.053774488764789502	0.125379144828392
39	33.50602022339664	0.1675301011169832	0.18661533884203893
40	12.873310620947885	0.0643665531073943	0.11779379960759436
41	12.184842018761834	0.060924210093809175	0.1376989048378439
42	13.2166858727908	0.06060834293639542	0.13405549121711008
43	20.980465590742163	0.10490232795371082	0.12759106502779327
44	16.28663918086592	0.0814331959493296	0.1136373993795381
45	16.587245851736725	0.08293622952868363	0.15198248235836898
46	8.406008845691176	0.0420300442284558	0.14156452359449936
47	13.28416703887636	0.06642083541943818	0.15704725331915403
48	21.84656771586573	0.1092383857932865	0.30921473467971755
49	14.456231840618376	0.07228115920309187	0.1297565169772788
50	17.510620188176894	0.075531094088448	0.138623005885206
51	42.9497911958578	0.21474895597928925	0.30608967049390656
52	22.430071770844712	0.11215035885422356	0.135273221002047
53	13.967964168062363	0.06983982084031182	0.12185041144675439
54	29.81557281400742	0.149077840700371	0.2793792051842455
55	20.341113338470905	0.1017055669923452	0.1455643264566415
56	9.728403092293416	0.04864201546146707	0.10107901614095141
57	15.15013889165457	0.0757506944582735	0.17074668208302268
58	13.22369171247615	0.06613345856238075	0.11139005764858576
59	11.30736128732578	0.0565368064366828	0.12268487458686038
60	14.754209157945991	0.07377104578972540	0.133070358657974897
61	24.702780813424683	0.12351390406721341	0.14983969891953292
62	44.951799458571195	0.22475899729285598	0.32494852552605874
63	19.482940305259657	0.09741470152629829	0.1357092072052071838
64	12.240786218111165	0.0612039310905582	0.13511926349799197
65	22.872925634371725	0.11436462817185862	0.17192233974831325
66	24.41998330969163	0.1209991654934582	0.13553448997184425
67	41.30718617053501	0.20653593085367505	0.2640602881547399
68	14.191087908563855	0.07095543945281927	0.13153282109039414
69	17.590522978466748	0.0879526148923373	0.10755815693784732
70	18.471287183772862	0.0923564359188643	0.1598775488112012
71	44.6757783783963527	0.22337889169817637	0.26719827804524726
72	14.233601775705653	0.07116800887852817	0.1316143202453988
73	29.9618103858902	0.1498090519294501	0.19142783796225432
74	16.399012164853655	0.08199506082426827	0.1196353349766498
75	33.61630918479199	0.16808154592395994	0.17719262728769639
76	9.960723958127824	0.04808361970963912	0.1268943208128904
77	12.96016067105377	0.06480080335726885	0.11412728307892689
78	14.5062983944028	0.0725314919722014	0.13981871019353237
79	14.745751463766985	0.07372875731883448	0.14327421365212137
80	7.72001789432734	0.03860008049716367	0.12215791066404552
81	21.609891512831893	0.108049457564515917	0.1291744550432848
82	20.59880808447137	0.1025490042423568	0.1223285593189162
83	16.534619160159817	0.08267309580079908	0.15256943925532385
84	18.7280620532734	0.0964603102676367	0.1181574563989695
85	13.628265762505085	0.06814132883625042	0.1559344275205427
86	14.64563453858059	0.07322817267925495	0.1459860116659205
87	9.941928555840532	0.0497064277920266	0.151415757511195
88	20.58701052290249	0.102935065261451244	0.13361417423637133
89	12.918979056265112	0.0645948952813255	0.09636173179219692
90	19.29007346107045	0.09645036730535224	0.1805163254914474
91	10.0111390553814	0.0500556970276907	0.10732318107050867
92	18.752070472914937	0.09376035236457468	0.14425744308202215
93	39.04498002009738	0.1952249901004869	0.21496697167860637
94	15.635728725415762	0.07817864362707881	0.17289243490432923
95	29.970820989652644	0.14985410494826323	0.2758209480913517
96	20.655491476895705	0.10327745738447852	0.1323359982235942
97	22.330109835693456	0.1116805917846728	0.11753123404234714
98	16.70554390834727	0.08352777195417364	0.1292040372497427
99	19.650189979907243	0.0982509489953621	0.1560868993916457
100	29.57617744086206	0.1478808872043103	0.24585721592249735